

National Tsing Hua University

Fall 2023 11210IPT 553000

Deep Learning in Biomedical Optical Imaging

Homework 4

馮渭中

Student ID: 107061222

1. Task A: Model Selection (20 pts)


1.1 Model Choice

在HW4中, 我選擇DenseNet和ResNet18。

1.2 Explanation

這邊我用的 pretrained model 為 ResNet18 和 DenseNet, ResNet 透過 skip connection 來解決訓練深層網路時會遇到梯度下降的問題, 綜合準確度 (Top1 accuracy) 與效率等考量, 試圖用 ResNet50 來進行 chest X-ray dataset 的分類。

DenseNet 則為 ResNet 的進階版, 將每一層都會跟其餘層做連接, 同時降低權種數。這些 model 都是用於訓練更深層的網路, 希望能在這次作業中看見他們的差異。



(Fig 00) Pretrained model-accuracy and operations

2. Task B: Fine-tuning the ConvNet (30 pts)

為了使輸入接近原model訓練條件，這邊先調整data的channel number, std and mean。使的 Input data shape 為 (1000, 3, 224, 224)

```
[11] import torch
from torchvision import transforms
from torch.utils.data import Dataset
from PIL import Image

class MedicalDataset(Dataset):
    def __init__(self, x, y, transform=None):
        self.x = x
        self.y = torch.from_numpy(y).long()

        # Define the default transformations if none are provided
        self.transform = transform or transforms.Compose([
            transforms.Resize((224, 224)),
            transforms.Grayscale(num_output_channels=3), # Converts 1-channel grayscale to 3-channel
            transforms.ToTensor(),
            transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]),
        ])

    def __len__(self):
        return len(self.x)

    def __getitem__(self, idx):
        # Convert the numpy array to a PIL image
        image = Image.fromarray(self.x[idx])

        # Apply the transformations to the PIL image
        if self.transform:
            image = self.transform(image)

        return image, self.y[idx]
```

(Fig 01) Data Preprocessing for resNet18

Fine-tuning透過pretrain model加上新的dense layer, 透過training data重新更新模型權重, 這也代表著trainin dataset需要足夠的訓練資料, 才能在低learning rate的情況下避免overfitting, 優點是對於與原pretrain model的訓練任務差異大時能更好的適應新任務。

2.1 Model Choice- ResNet18.

```
import torch
import torch.nn as nn
import torch.optim as optim
from torchvision import models, transforms, datasets
from torch.utils.data import DataLoader

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")


# 1. Load the pre-trained ResNet-18 model
model = models.resnet18(weights=models.ResNet18_Weights.IMAGENET1K_V1)

# 2. Modify the fully connected layer for binary classification
num_fts = model.fc.in_features
model.fc = nn.Linear(num_fts, 2) # Change the output features to 2
model.to(device)

# 3. Define a loss function and optimizer
criterion = nn.CrossEntropyLoss()

# Only parameters of the final layer are being optimized as
optimizer = optim.SGD(model.fc.parameters(), lr=0.001, momentum=0.9)
```

(Fig 02) ResNet18 + binary classification




(Fig 03) *ResNet18-fine tune*_Loss and Accuracy

這邊可以看到在10 epochs內loss和accuracy優化的速度極快, 約3 epochs就已經達到91%的準確度。

2.2 Model Choice- DenseNet

DenseNet這邊可以看到loss的下降更為穩定, 然而相較於ResNet18有些underfitting的情快, 但可以看到兩種pretrain model透過fine tune的方法都可以明顯優於HW2的訓練結果。




(Fig 04) *DenseNet-fine tune*_Loss and Accuracy

3 Task C: ConvNet as Fixed Feature Extractor (30 pts)

Feature_Extraction這個方法在訓練過程最明顯的差異在於"訓練速度快", 由於不更新 pretrained layer的權重, 而只訓練用於分類的dense layer, 在運算速度能力有限的時候可以有有效的訓練模型。


而另一個好處則是當訓練資料過少時, 當pretrained model可以有效捕捉圖片特徵時, 使用 Feature Extraction可以有效避免overfitting。

3.1 Discussion - ResNet18



(Fig 05) *ResNet18-feature extraction*_Loss and Accuracy

3.2 Discussion - DenseNet



(Fig 06) *DenseNet-feature extraction*_Loss and Accuracy

4 Task D: Comparison and Analysis (10 pts)

4.1 Discussion

就訓練結果而言，兩種方法best accuracy都接近95%且loss也都下降到0.2左右，就表現上十分接近。然而最明顯的是訓練時間，使用fine tuning的方法明顯較慢，由於更新的權重較多對運算時間較多且效率較差。以下針對兩種方法進行比較：

- (1) Flexibility to new data : Fine tuning能更好的適應差異大的訓練任務，而Featrue extractor要求任務性質接近。
- (2) Training time and compute : Fine tuning 訓練速度較耗時，這也與我訓練觀察到的結果相同。
- (3) Risk of overfitting : 在資料數量較少時，Fine tuning overfitting的風險較高，然而若資料數量夠且訓練的好，Fine tuning的表現會優於 Feature extractor。

5 Task E: Test Dataset Analysis (10 pts)

5.1 Discussion

總共2000筆資料有些過少，若透過更深層複雜的網路層訓練會碰到overfitting的問題，若能透過適當的data augmentation可以得到較好的訓練效果。